

MAC0317/MAC5920

Introdução ao Processamento de Sinais Digitais

Seção 6.5: Bancos de Filtros para Sinais Finitos

Seção 6.5.1: Estratégias de extensão

Para estender a ideia de bancos de filtros para sinais finitos, adotaremos a estratégia de estender o sinal finito para o contexto bi-infinito.

Seja $x \in \mathbb{C}^N$. Queremos representá-lo através de um sinal $\tilde{x} \in L^2(\mathbb{Z})$. Algumas opções são:

1. *extensão com zeros*

$$\tilde{x}_k = \begin{cases} x_k, & k \in \{0, 1, \dots, N-1\} \\ 0, & \text{c.c.} \end{cases}$$

1. *extensão periódica*

$$\tilde{x}_k = x_{k \bmod N}, \quad \forall k \in \mathbb{Z}$$

1. *espelhamento + extensão periódica*

A extensão periódica do tipo 2 corresponde ao sinal

$$\overbrace{\dots, x_{N-2}, x_{N-1}, x_0, x_1, \dots, x_{N-2}, x_{N-1}, x_0, x_1, \dots}$$

ao passo que a extensão do tipo 3 corresponde a

$$\overbrace{\dots, x_3, x_2, x_1, x_0, x_0, x_1, \dots, x_{N-2}, x_{N-1}, x_{N-1}, x_{N-2}, \dots}$$

e é também chamada de *extensão simétrica de meio-ponto* pois o espelhamento ocorre entre duas amostras. Existe também a *extensão simétrica de ponto inteiro*:

$$\overbrace{\dots, x_3, x_2, x_1, x_0, x_1, \dots, x_{N-2}, x_{N-1}, x_{N-2}, \dots}$$

Observe que nenhuma dessas extensões geram sinais de energia finita (em $L^2(\mathbb{Z})$). Será necessário fazer uma espécie de *gambiarra* para permitir o uso daquela teoria.

Extensões pseudo-periódicas

As extensões 2 e 3 acima podem ser feitas um número finito de vezes, para garantir que $\tilde{x} \in L^2(\mathbb{Z})$. A título de exemplo, desenvolveremos a DWT em \mathbb{C}^N a partir da extensão periódica (caso 2 acima). Trabalharemos com extensões que chamaremos de *pseudo-periódicas*: para q "grande o suficiente" definiremos:

$$\tilde{x}_k = \begin{cases} x_{k \bmod N}, & -qN \leq k \leq +qN \\ 0, & \text{c.c.} \end{cases}$$

Análise da extensão periódica

Por sua maior simplicidade, consideraremos a extensão periódica sem reflexões simétricas na análise do banco de filtros.

Teorema 6.5.1: Seja $x \in C^N$, e considere um banco de filtros $\{l_a, h_a, l_s, h_s\}$ onde todos os filtros tem N ou menos coeficientes. Se interpretarmos esses filtros como elementos de C^N tomando os índices módulo N , e se tomarmos todas as convoluções como convoluções circulares em C^N , então a transformação

$$x \mapsto X = (X_l, X_h) \quad \left(C^N \mapsto C^N \right)$$

é inversível, e sua inversa é dada por

$$X \mapsto x = l_s * U(X_l) + h_s U(X_h) \quad \left(C^N \mapsto C^N \right).$$

Prova: Mostraremos que a utilização da transformada baseada em um banco de filtros com reconstrução perfeita no sinal $\tilde{x} \in L^2(\mathbb{Z})$ equivale à mesma sequência de operações em \mathbb{C}^N a partir de $x \in \mathbb{C}^N$, interpretando as convoluções como convoluções circulares. Pela propriedade de reconstrução perfeita em $L^2(\mathbb{Z})$, temos que os sinais

$$\tilde{X}_l = D(\tilde{x} * l_a),$$

$$\tilde{X}_h = D(\tilde{x} * h_a),$$

onde $*$ é a convolução (linear) em $L^2(\mathbb{Z})$, permitem a reconstrução de \tilde{x} através da expressão

$$\tilde{x} = U(\tilde{X}_l) * l_s + U(\tilde{X}_h) * h_s.$$

Dado $x \in \mathbb{C}^N$, podemos definir

$$X_I = D(x * l_a) \in \mathbb{C}^{N/2}$$

onde $*$ é a convolução circular

$$(x * l_a)_n = \sum_{k=0}^{N-1} (l_a)_k x_{n-k},$$

e $D \in \mathbb{R}^{\frac{N}{2} \times N}$ é a matriz tal que $D_{i,2i} = 1$ e $D_{i,j} = 0$ caso contrário:

Na etapa de ressíntese, vamos combinar X_l e X_h através da expressão

$$U(X_l) * l_s + U(X_h) * h_s = \hat{x}$$

$$\text{e } U = D^T \in \mathbb{R}^{N \times \frac{N}{2}}.$$

Queremos mostrar que \hat{x} (versão ressíntetizada em domínio finito) é idêntico a x .

Para fazer isso, vamos observar as correspondências entre X_l e \tilde{X}_l e entre X_h e \tilde{X}_h . Note inicialmente que as convoluções linear (em Z) e circular (em C^N) coincidem nas amostras "centrais" $n = 0, 1, \dots, N - 1$:

$$\begin{aligned}
 (\tilde{x} * l_a)_n &= \sum_{k=-\infty}^{\infty} (l_a)_k \tilde{x}_{n-k} && \text{(convolução linear)} \\
 &= \sum_{k=0}^{N-1} (l_a)_k \tilde{x}_{n-k} \\
 &= \sum_{k=0}^{N-1} (l_a)_k x_{(n-k \% N)} \\
 &= (x * l_a)_n && \text{(convolução circular)}
 \end{aligned}$$

pois $(l_a)_k = 0$ se $k \notin \{0, 1, \dots, N - 1\}$ e $\tilde{x}_{n-k} = x_{n-k}$ para $n, k \in \{0, 1, \dots, N - 1\}$.

Um argumento semelhante mostra que $(x * h_a)_n = (\tilde{x} * h_a)_n$ para $n = 0, 1, \dots, N - 1$.

A subamostragem D preservará apenas as componentes de índice par, tanto no contexto infinito quanto no finito. Assim, a partir do conhecimento de $X_l, X_h \in \mathbb{C}^{N/2}$, podemos recuperar a informação completa de $\tilde{X}_l, \tilde{X}_h \in L^2(\mathbb{Z})$, sendo que

$$\begin{aligned}(\tilde{X}_l)_{n+kN/2} &= (X_l)_n, \\(\tilde{X}_h)_{n+kN/2} &= (X_h)_n, \quad \text{para } n = 0, 1, \dots, \frac{N}{2} - 1, \quad \forall k \in \mathbb{Z}.\end{aligned}$$

Notando que as convoluções com os filtros l_s, h_s de ressíntese possuem a mesma propriedade em relação às convoluções, podemos ver que, para $n = 0, 1, \dots, N - 1$, o sinal $\hat{x} \in C^N$ reconstruído pela aplicação do banco de filtros em C^N coincide com o sinal $\tilde{x} \in L^2(Z)$ perfeitamente reconstruído em $L^2(Z)$ e portanto com o sinal finito original $x \in C^N$:

$$\hat{x}_n = [U(X_l) * l_s + U(X_h) * h_s]_n \quad (\text{convolução circular em } C^N)$$

$$= [U(X_l) * l_s]_n + [U(X_h) * h_s]_n$$

$$= [U(\tilde{X}_l) * l_s]_n + [U(\tilde{X}_h) * h_s]_n \quad (\text{convolução linear em } L^2(Z))$$

$$= [U(\tilde{X}_l) * l_s + U(\tilde{X}_h) * h_s]_n$$

$$= \tilde{x}_n \quad (\text{reconstrução perfeita em } L^2(Z))$$

$$= x_n$$

Exemplo 6.7: considere a DWT com o banco de filtros de Haar ortogonalizado, que satisfaz $(l_s)_k = (l_a)_{-k}$, $\forall k$ e $(h_s)_k = (h_a)_{-k}$, $\forall k$, aplicada a um vetor $x \in \mathbb{C}^4$:

Assim

$$X = W_2 \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

onde

Exemplo 6.8

Na ressíntese, temos $x = U(X_l) * I_s + U(X_h) * h_s$:

ou seja,

$$x = W_2 \begin{pmatrix} X_0 \\ X_1 \\ X_2 \\ X_3 \end{pmatrix}$$

onde

Observe que:

- $W_4^s = (W_4^q)^T$
- *todas as colunas (e linhas) de W_4^s e W_4^q são ortogonais (2 a 2)*

Logo

$$W_4^s W_4^q = I \quad (\text{pois a IDWT é a inversa da DWT})$$

$$W_4^q (W_4^q)^T = I \quad (\text{ortonormalidade do banco de filtros})$$

Seção 6.5.3: Formulação Matricial da DWT em \mathbb{C}^N

DWT (Análise): dado $x \in \mathbb{C}^N$,

IDWT (Síntese): dado $X \in \mathbb{C}^N$,

$$x = U(X_l) * l_s + U(X_h) * h_s$$

$$= M_{l_s} U X_l + M_{h_s} U X_h$$

$$= \begin{bmatrix} M_{l_s} U & M_{h_s} U \end{bmatrix} \begin{bmatrix} X_l \\ X_h \end{bmatrix}$$

$$= W_N^S X$$

Se um banco de filtros possui a propriedade

$$(l_s)_k = (l_a)_{-k}, \forall k$$

$$(h_s)_k = (h_a)_{-k}, \forall k$$

sendo denominados *filtros adjuntos* (ou revertidos no tempo), temos (exercício 4.9)

$$M_{l_s} = (M_{l_a})^T$$

$$M_{h_s} = (M_{h_a})^T.$$

Neste caso,

$$\begin{aligned}
 W_N^S &= \begin{bmatrix} M_{l_s} U & M_{h_s} U \end{bmatrix} \\
 &= \begin{bmatrix} (M_{l_a})^T U^T & (M_{h_a})^T U^T \end{bmatrix} \\
 &= \begin{bmatrix} (M_{l_a} U)^T & (M_{h_a} U)^T \end{bmatrix} \\
 &= \begin{bmatrix} M_{l_a} U \\ M_{h_a} U \end{bmatrix}^T \\
 &= (w_N^a)^T
 \end{aligned}$$

Seção 6.5.4: Formulação Matricial da DWT de Vários Níveis

DWT de 2 níveis: lembrando do diagrama

$$x \mapsto \begin{bmatrix} X_I \\ X_h \end{bmatrix} \mapsto \begin{bmatrix} X_{II} \\ X_{Ih} \end{bmatrix}$$

X_h

podemos escrever

DWT de 3 níveis

$$x \mapsto \begin{bmatrix} X_I \\ X_h \end{bmatrix} \mapsto \begin{bmatrix} X_{II} \\ X_{Ih} \end{bmatrix} \mapsto \begin{bmatrix} X_{III} \\ X_{IIh} \\ X_{Ih} \\ X_h \end{bmatrix}$$

Custo de implementação da DWT de vários níveis

É fácil ver que o custo de implementação da DWT, independentemente do número de níveis, é sempre **linear**, se considerarmos que os filtros têm uma quantidade pequena $O(1)$ de coeficientes.

Isso ocorre pois cada estágio terá custo linear (limitado por αL) na quantidade L de coeficientes processados, e essa quantidade será $L = N$ no 1º estágio, $L = N/2$ no 2º estágio, e assim por diante, logo o custo total será limitado por

$$\alpha \left(N + \frac{N}{2} + \frac{N}{4} + \dots \right) \leq \alpha 2N.$$

Exemplo 6.9

Voltamos ao sinal do exemplo 6.2, para inspecionar as transformadas de vários estágios:



$$X^{(1)} = \begin{pmatrix} X_I, & & & X_h \end{pmatrix}$$

$$X^{(2)} = \begin{pmatrix} X_{II}, & & X_{Ih}, & X_h \end{pmatrix}$$



$$X^{(3)} = \begin{pmatrix} X_{III}, & X_{IIh}, & X_{Ih}, & X_h \end{pmatrix}$$

$$X^{(4)} = \begin{pmatrix} X_{IIII}, & X_{IIIIh}, & X_{IIh}, & X_{Ih}, & X_h \end{pmatrix}$$




```
In [3]: plotdwt(0)  
plotdwt(1)
```



```
In [4]: plotdwt(2)  
plotdwt(3)
```



```
In [5]: plotdwt(4)  
plotdwt(5)
```



Reconstrução da DWT por camadas

No primeiro nível da DWT, temos

$$\begin{aligned}x &= W_N^S \begin{pmatrix} X_l \\ X_h \end{pmatrix} \\&= W_N^S \begin{pmatrix} X_l \\ 0 \end{pmatrix} + W_N^S \begin{pmatrix} 0 \\ X_h \end{pmatrix} \\&= \alpha_1(x) + \delta_1(x)\end{aligned}$$

onde α_1 é a reconstrução usando *apenas* os coeficientes de aproximação (como se X_h fosse = 0), e δ_1 a reconstrução usando *apenas* os coeficientes de detalhes (como se X_l fosse = 0). Chamamos as reconstruções α_1 e δ_1 de aproximação e detalhes de 1ª

Considere agora a DWT de segunda ordem. Podemos escrever

$$\begin{aligned}
 x &= W_N^{S_1(2)} \begin{pmatrix} X_{ll} \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ X_{lh} \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ X_h \end{pmatrix} \\
 &= W_N^{S_1(2)} \begin{pmatrix} X_{ll} \\ 0 \\ 0 \end{pmatrix} + W_N^{S_1(2)} \begin{pmatrix} 0 \\ X_{lh} \\ 0 \end{pmatrix} + W_N^S \begin{pmatrix} 0 \\ 0 \\ X_h \end{pmatrix} \\
 &= \alpha_2(x) + \delta_2(x) + \delta_1(x)
 \end{aligned}$$

No caso da DWT de terceira ordem, temos

$$\begin{aligned}
 x &= W_N^{S,(3)} \begin{pmatrix} X_{lll} \\ 0 \\ 0 \\ 0 \end{pmatrix} + W_N^{S,(3)} \begin{pmatrix} 0 \\ X_{llh} \\ 0 \\ 0 \end{pmatrix} + W_N^{S,(2)} \begin{pmatrix} 0 \\ 0 \\ X_{lhh} \\ 0 \end{pmatrix} + W_N^{S,(1)} \begin{pmatrix} 0 \\ 0 \\ 0 \\ X_h \end{pmatrix} \\
 &= \alpha_3(x) + \delta_3(x) + \delta_2(x) + \delta_1(x)
 \end{aligned}$$

e em geral

$$\alpha_r(x) = \alpha_{r+1}(x) + \delta_{r+1}(x)$$

ou

$$\alpha_{r+1} = \alpha_r(x) - \delta_{r+1}(x)$$

Figuras 6.14 e 6.15

Neste exemplo veremos mais uma vez as reconstruções do sinal do exemplo 6.2, usando apenas os coeficientes de aproximação de ordem M .


```
In [7]: interactive(plot_reconstruction, family=r,)
```